

Voorspellen van langdurige treinverstoringen

Een volledige analyse volgens CRISP-DM

WERKVORM Individueel	FRAMEWORK CRISP-DM	OMVANG DATA 6.676 rijen	MODELTYPE Classificatie
--------------------------------	------------------------------	-----------------------------------	-----------------------------------

Disclaimer over het gebruik van AI

Bij het opstellen van deze opdracht is AI gebruikt om de inhoud en moeilijkheidsgraad af te stemmen op het niveau van tweedejaars hbo-studenten. AI is ook gebruikt om het taalgebruik aan te passen aan dit niveau. De inhoud, leerdoelen en beoordelingscriteria zijn door de docent gecontroleerd en vastgesteld.

1. Opdracht in het kort

Je voert individueel een volledige data-analyse uit volgens CRISP-DM. Je werkt met gegevens over treinverstoreningen in Nederland. De nadruk ligt op het begrijpen, opschonen, transformeren en modelleren van de data. Je sluit af met een onderbouwde test van het voorspellende model. De fase Deployment valt buiten deze opdracht.

Businessvraag: Kan op het moment dat een treinverstoring begint worden voorspeld of deze langer dan 60 minuten zal duren, op basis van de oorzaak, het getroffen traject, het aantal getroffen stations en het startmoment?

1.1 Beoogd resultaat

Aan het einde lever je een reproduceerbare analyse op. Een beoordelaar moet je gegevensbewerkingen kunnen volgen, je modellen opnieuw kunnen trainen en je uitkomsten kunnen controleren. Elke keuze krijgt een korte inhoudelijke onderbouwing.

Onderdeel	Wat je aantoon
Data begrijpen	Je herkent gegevenstypen, structuur, verdelingen en kwaliteitsproblemen.
Data voorbereiden	Je manipuleert data aantoonbaar en maakt een bruikbare modeldataset.
Voorspellen	Je bouwt een baseline en minimaal twee classificatiemodellen.
Testen	Je beoordeelt het gekozen model op ongeziene testdata en verklaart fouten.
Communiceren	Je koppelt de resultaten terug aan de businessvraag en benoemt beperkingen.

1.2 Werkwijze

1. **Werk uitsluitend in code.** Pas het oorspronkelijke CSV-bestand niet handmatig aan.
2. **Structureer je notebook volgens CRISP-DM.** Gebruik voor elke fase een duidelijke Markdown-kop.
3. **Combineer code en uitleg.** Laat relevante uitvoer zien en beschrijf direct wat die uitvoer betekent.
4. **Werk reproduceerbaar.** Gebruik vaste random states en zorg dat het notebook van boven naar beneden uitvoerbaar is.
5. **Bewaar tussenresultaten bewust.** Maak duidelijk wanneer je met ruwe, opgeschoonde of gemodelleerde data werkt.

2. Dataset en uitgangspunten

Je ontvangt twee bestanden. Dataset.csv bevat de waarnemingen. Beschrijving van de data.docx bevat de betekenis van de kolommen. Lees de databeschrijving voordat je de CSV analyseert.

Bestand	Gebruik
Dataset.csv	Ruwe gegevens met 6.676 rijen en 14 kolommen. Het scheidingsteken is een puntkomma.
Beschrijving van de data.docx	Datadictionary met definities en aandachtspunten per kolom.

Elke rij stelt één geregistreerde verstoring voor. De dataset bestrijkt 2025. Sommige velden bevatten één waarde. Andere velden bevatten meerdere waarden die met komma's zijn gescheiden. De dataset bevat bovendien ontbrekende, afwijkende of mogelijk inconsistente waarden. Het is jouw taak om deze systematisch te onderzoeken.

2.1 Voorspeldoel

Maak een binaire doelvariabele `long_disruption`. De waarde is 1 wanneer de opgeschoonde duur groter is dan 60 minuten. De waarde is 0 wanneer de duur 60 minuten of korter is. Leg vast welke bron je voor de duur gebruikt en hoe je inconsistenties behandelt.

Waarschuwing voor datalekken: `end_time` en `duration_minutes` zijn bij de start van een verstoring nog niet beschikbaar. Je mag deze kolommen gebruiken om de doelvariabele te controleren en te maken. Je mag ze niet opnemen als invoerkenmerk. `rdt_id` is een identificatieveld en is evenmin een inhoudelijk invoerkenmerk.

2.2 Kolomgroepen

Groep	Kolommen	Aandachtspunt
Identificatie	<code>rdt_id</code>	Controleer uniciteit. Gebruik het ID niet als voorspellend kenmerk.
Trajecten	<code>ns_lines</code> , <code>rdt_lines</code> , <code>rdt_lines_id</code>	De databeschrijving vermeldt dat <code>ns_lines</code> niet is gestandaardiseerd. Onderzoek het verschil.
Stations	<code>rdt_station_names</code> , <code>rdt_station_codes</code>	De velden kunnen meerdere door komma's gescheiden waarden bevatten.
Oorzaken	<code>cause_nl</code> , <code>cause_en</code> , <code>statistical_cause_nl</code> , <code>statistical_cause_en</code> , <code>cause_group</code>	De databeschrijving meldt dat oorzaken tijdens een verstoring kunnen wijzigen. Beoordeel of het veld startinformatie voorstelt.

Groep	Kolommen	Aandachtspunt
Tijd en duur	start_time, end_time, duration_minutes	Controleer parsing, volgorde, duur en plausibiliteit.

3. Vereist bewijs per CRISP-DM-fase

De volgende hoofdstukken vormen de kern van de opdracht. Neem dezelfde volgorde over in je notebook en rapport. Een figuur of tabel zonder interpretatie geldt niet als volledige onderbouwing.

3.1 Business Understanding

Neem de gegeven businessvraag letterlijk op aan het begin van je analyse. Een uitgebreide businessanalyse is niet nodig. Beschrijf alleen in één of twee zinnen dat het om een binaire voorspelling bij de start van een verstoring gaat.

Resultaat van deze fase: De businessvraag staat zichtbaar in het notebook en de te voorspellen klasse is correct omschreven.

3.2 Data Understanding

Onderzoek eerst de ruwe data. Reinig nog niets voordat je de oorspronkelijke toestand hebt vastgelegd. Toon niet alleen functies zoals head(), info() en describe(). Leg uit wat de uitvoer betekent voor deze dataset.

A. Inlezen en eerste controle

6. **Lees het bestand correct in.** Toon het gebruikte scheidingsteken en controleer of alle 14 kolommen afzonderlijk zijn ingelezen.
7. **Rapporteer de omvang.** Noem het aantal rijen, kolommen en unieke verstoring-ID's.
8. **Toon een beperkte steekproef.** Gebruik bijvoorbeeld de eerste en laatste vijf rijen en enkele willekeurige rijen.
9. **Controleer de periode.** Bepaal de vroegste en laatste bruikbare startdatum.

B. Gegevenstypen

Maak een overzicht voor alle 14 kolommen. Vermeld per kolom de betekenis, het door pandas ingelezen datatype, het gewenste datatype en het inhoudelijke meetniveau. Maak onderscheid tussen identifier, nominale categorie, numerieke waarde, datum/tijd en multi-value tekstveld. Let erop dat een kolom met cijfers niet automatisch een numerieke variabele is.

C. Verkennende analyse

10. **Numerieke beschrijving.** Onderzoek duration_minutes met centrum-, spreidings- en percentielmaten.
11. **Categorische beschrijving.** Onderzoek minimaal cause_group, statistical_cause_nl en rdt_lines.
12. **Tijdsverdeling.** Onderzoek het aantal verstoringen per maand, weekday of uur.
13. **Visualisaties.** Maak minimaal vier leesbare figuren. Gebruik ten minste een verdelingsplot, een categorische vergelijking, een tijdsplot en een visualisatie van ontbrekende waarden.
14. **Interpretatie.** Schrijf onder elke figuur twee of drie zinnen over het patroon en het mogelijke belang voor de voorspelling.

D. Datakwaliteit

Voer aantoonbare controles uit op volledigheid, uniciteit, validiteit, consistentie en plausibiliteit. Schrijf de controles als code. Vermeld per probleem hoeveel rijen of waarden het raakt. Onderzoek ten minste de volgende punten.

15. **Ontbrekende waarden.** Bepaal aantallen en percentages per kolom. Onderzoek ook welke kolommen tegelijk ontbreken.
16. **Dubbele gegevens.** Controleer volledige dubbele rijen en dubbele waarden van rdt_id.
17. **Datumvaliditeit.** Controleer of start_time en end_time kunnen worden omgezet en of de eindtijd niet voor de starttijd ligt.
18. **Duurconsistentie.** Vergelijk duration_minutes met het verschil tussen start_time en end_time. Onderzoek zowel kleine als grote afwijkingen.
19. **Multi-value consistentie.** Vergelijk het aantal trajectnamen met traject-ID's en het aantal stationsnamen met stationcodes.
20. **Categorische kwaliteit.** Controleer hoofdletters, spaties, lege teksten, zeldzame categorieën en mogelijke dubbelingen in betekenis.
21. **Uitschieters.** Spoor uitzonderlijk lange of korte verstoringen op. Maak onderscheid tussen een echte uitzonderlijke gebeurtenis en een invoerfout.
22. **Geschiktheid als kenmerk.** Beoordeel rdt_id, ns_lines, de oorzaakvelden, end_time en duration_minutes vanuit het voorspelmoment.

Sluit Data Understanding af met een datakwaliteitsrapport. Gebruik minimaal vijf concreet gevonden problemen. Vul per probleem de omvang, het mogelijke gevolg en je voorgenomen behandeling in.

Kolom(men)	Probleem	Aantal / %	Gevolg voor analyse	Voorgenomen actie
...	...	...	...	...
...	...	...	...	...

Kolom(men)	Probleem	Aantal / %	Gevolg voor analyse	Voorgenomen actie
...	...	...	...	...

Resultaat van deze fase: Een onderbouwd beeld van de ruwe data, de variabelen, de verdelingen en de datakwaliteit. De analyse bevat exacte aantallen en inhoudelijke interpretaties.

3.3 Data Preparation

Maak vanuit de ruwe data een modeldataset. Laat elke bewerking in code zien. Werk bij voorkeur met een nieuwe DataFrame, zodat de ruwe data beschikbaar blijft voor vergelijking.

A. Opschonen en selecteren

23. **Zet datatypes om.** Converteer datums en numerieke waarden expliciet. Controleer mislukte conversies.
24. **Behandel ontbrekende waarden.** Maak per relevante kolom een beargumenteerde keuze tussen verwijderen, imputeren, een categorie Unknown maken of het kenmerk niet gebruiken.
25. **Behandel inconsistenties.** Los gevonden problemen met tijd, duur en multi-value velden aantoonbaar op.
26. **Behandel uitschieters.** Verwijder uitschieters niet automatisch. Toon de invloed en leg je keuze vast.
27. **Selecteer bronkolommen.** Gebruik alleen kenmerken die bij de start van een verstoring beschikbaar kunnen zijn.

B. Data manipuleren en kenmerken maken

Maak minimaal vijf nieuwe invoerkenmerken. Minimaal twee kenmerken komen uit start_time. Minimaal één kenmerk komt uit een multi-value veld. De onderstaande mogelijkheden geven richting. Je hoeft ze niet allemaal te gebruiken.

Bron	Mogelijke kenmerken	Te tonen bewerking
start_time	start_hour, month, day_of_week, is_weekend	Datumonderdelen afleiden en het nieuwe datatype controleren.
rdt_station_names	number_of_affected_stations	Tekst splitsen op komma, witruimte verwijderen en elementen tellen.
rdt_lines of rdt_lines_id	number_of_affected_lines, primary_line	Multi-value veld opsplitsen of samenvatten.
cause_group	Gegroepeerde oorzaak	Categorieën controleren en geschikt coderen.

Bron	Mogelijke kenmerken	Te tonen bewerking
statistical_cause_nl	Zeldzame oorzaken samengevoegd	Frequentiedrempel onderbouwen en mapping reproduceerbaar uitvoeren.

Toon vóór en na een bewerking enkele representatieve rijen. Gebruik functies zoals `assign()`, `map()`, `replace()`, `str.split()`, `explode()`, `groupby()`, `merge()` of `pivot_table()` waar deze inhoudelijk passen. Alleen kolommen verwijderen geldt niet als voldoende datamanipulatie.

C. Doelvariabele en datalekken

28. **Controleer de duur.** Bepaal eerst welke waarden betrouwbaar genoeg zijn voor de doelvariabele.
29. **Maak long_disruption.** Gebruik de grens groter dan 60 minuten.
30. **Controleer de klasseverdeling.** Rapporteer aantallen en percentages voor klasse 0 en klasse 1.
31. **Verwijder lekken uit X.** Neem `end_time`, `duration_minutes`, `long_disruption` en afgeleide informatie uit de eindtijd niet op als invoerkenmerken.

D. Train-test-splitsing en preprocessing

32. **Splits X en y.** Gebruik 80% trainingsdata en 20% testdata. Gebruik `stratify=y` en `random_state=42`.
33. **Fit alleen op training.** Imputers, encoders en scalers mogen geen informatie uit de testset gebruiken.
34. **Gebruik een pipeline.** Werk met `ColumnTransformer` en `Pipeline`, of toon een aantoonbaar gelijkwaardige aanpak.
35. **Codeer categorische kenmerken.** Gebruik een methode die ook onbekende categorieën in de testset kan verwerken.
36. **Schaal waar nodig.** Leg uit waarom een gekozen algoritme wel of geen schaling nodig heeft.

E. Controle na voorbereiding

Maak een compacte vergelijking tussen de ruwe en voorbereide data. Rapporteer het aantal rijen en kolommen, ontbrekende waarden, datatypes, geselecteerde invoerkenmerken, uitgesloten kolommen en de klasseverdeling. Controleer met assertions of de gekozen voorwaarden kloppen.

Resultaat van deze fase: Een reproduceerbare modeldataset en preprocessing-pipeline. De gemaakte kenmerken zijn inhoudelijk verdedigbaar en de testset is nog niet gebruikt om keuzes te leren.

3.4 Modeling

Bouw classificatiemodellen die `long_disruption` voorspellen. Gebruik `scikit-learn`. Vergelijk altijd met een eenvoudige baseline. Hierdoor kun je aantonen dat een model daadwerkelijk meerwaarde heeft ten opzichte van een vaste gokstrategie.

Model	Minimum	Wat je rapporteert
Baseline	DummyClassifier met een beargumenteerde strategie	Testbare referentieprestatie en reden voor de gekozen strategie.
Model 1	Logistische regressie of een vergelijkbaar lineair model	Pipeline, instellingen en interpretatie van belangrijke coëfficiënten.
Model 2	Decision tree, random forest of een ander niet-lineair model	Pipeline, instellingen en interpretatie van feature importance of modelgedrag.

37. **Train alle modellen op dezelfde trainingsset.** Gebruik dezelfde targetdefinitie en dezelfde eerlijke set invoerkenmerken.
38. **Gebruik cross-validatie op de trainingsset.** Pas bij voorkeur vijf folds toe en rapporteer gemiddelde en spreiding van de gekozen metriek.
39. **Onderzoek enkele hyperparameters.** Gebruik `GridSearchCV`, `RandomizedSearchCV` of een beperkte handmatige vergelijking. Houd het zoekgebied uitlegbaar.
40. **Leg modelkeuzes uit.** Beschrijf waarom de modellen passen bij categorische en numerieke kenmerken in deze dataset.
41. **Selecteer één eindmodel.** Baseer de keuze op trainings- en validatieresultaten. Bekijk de testset pas daarna voor de definitieve test.

Resultaat van deze fase: Een baseline, minimaal twee getrainde voorspellende modellen en een onderbouwde keuze voor één eindmodel.

3.5 Evaluation

Test het gekozen eindmodel eenmaal op de apart gehouden testset. Vergelijk de uitkomst met de baseline en met de resultaten uit cross-validatie. Een hoge accuracy alleen is geen volledige evaluatie.

A. Verplichte testresultaten

Onderdeel	Vereist bewijs
Confusion matrix	Toon aantallen true negatives, false positives, false negatives en true positives.

Onderdeel	Vereist bewijs
Accuracy	Rapporteer de totale fractie correcte voorspellingen.
Precision voor klasse 1	Leg uit welk deel van de voorspelde langdurige verstoringen werkelijk langdurig was.
Recall voor klasse 1	Leg uit welk deel van de werkelijk langdurige verstoringen is gevonden.
F1-score voor klasse 1	Gebruik deze maat om precision en recall gezamenlijk te beoordelen.
ROC-AUC	Rapporteer deze maat wanneer het model kansen kan voorspellen. Toon bij voorkeur ook de ROC-curve.

Kies één primaire evaluatiemaat en onderbouw die keuze vanuit de businessvraag. Bespreek ook de fout die volgens jou het zwaarst weegt: een langdurige verstoring missen of een korte verstoring ten onrechte als langdurig aankondigen.

B. Vergelijking en foutanalyse

42. **Vergelijk met de baseline.** Laat zien hoeveel het eindmodel per relevante metriek verbetert.
43. **Vergelijk validatie en test.** Bespreek mogelijke overfitting wanneer de prestaties sterk uiteenlopen.
44. **Analyseer fouten.** Bekijk minimaal tien fout voorspelde rijen. Vergelijk false positives en false negatives.
45. **Zoek patronen.** Onderzoek fouten per cause_group en minstens één ander kenmerk, zoals tijdstip of aantal stations.
46. **Interpreteer het model.** Toon belangrijke coëfficiënten, feature importances of een andere passende uitleg.

C. Eindconclusie

Beantwoord de businessvraag rechtstreeks. Noem de testprestatie van het eindmodel, de gekozen primaire metriek en de vergelijking met de baseline. Geef daarna minimaal drie beperkingen. Bespreek in elk geval dat historische registraties niet alle operationele informatie bevatten, dat een laatst geregistreerde oorzaak mogelijk niet gelijk is aan de oorzaak die bij de start bekend was, dat categorieën in de tijd kunnen veranderen en dat de test binnen één kalenderjaar niet automatisch toekomstige prestaties garandeert.

Formuleer ten slotte een advies: is het model op basis van deze analyse bruikbaar als experimenteel beslisondersteunend hulpmiddel, alleen geschikt voor verder onderzoek of onvoldoende bruikbaar? Deployment hoeft je niet uit te werken.

Resultaat van deze fase: Een controleerbare test op ongeziene data, een foutanalyse en een genuanceerd antwoord op de businessvraag.

4. In te leveren producten

Product	Eisen
Jupyter Notebook (.ipynb)	Volledige analyse in CRISP-DM-volgorde. Alle codecellen zijn uitgevoerd. Het notebook draait van boven naar beneden zonder handmatige tussenstappen.
Voorbereide data (.csv)	De uiteindelijke modeldataset vóór one-hot encoding. Kolomnamen en datatypes zijn herkenbaar. Voeg geen volledige gecodeerde sparse matrix toe.
README (.md of .txt)	Korte instructie voor starten, gebruikte Python-versie, benodigde packages en bestandsnamen.

Lever de drie bestanden samen in. Gebruik relatieve paden in je notebook. Neem geen persoonlijke gegevens of lokale absolute paden op in de code.

5. Beoordeling

De eerste fase weegt beperkt mee. Data Understanding, Data Preparation, Modeling en Evaluation vormen samen 95% van het cijfer. De beoordelaar kijkt naar correcte uitvoering, onderbouwing, reproduceerbaarheid en de mate waarin je eigen code en uitleg het proces aantoonbaar maken.

Fase	Criterium	Punten
Business Understanding	Businessvraag correct opgenomen en voorspeldoel kort omschreven.	5
Data Understanding	Correct inlezen, structuur en periode vastgesteld.	4
Data Understanding	Alle kolommen inhoudelijk en technisch getypeerd.	5
Data Understanding	Passende beschrijvende analyses en minimaal vier geïnterpreteerde figuren.	5
Data Understanding	Systematische kwaliteitscontroles met exacte omvang en impact.	6
Data Preparation	Onderbouwde behandeling van ontbrekende, inconsistente en afwijkende waarden.	10
Data Preparation	Aantoonbare manipulatie en minimaal vijf bruikbare nieuwe kenmerken.	10
Data Preparation	Correcte target, geen datalekken, eerlijke splitsing en preprocessing-pipeline.	10
Modeling	Correcte en uitlegbare baseline.	4
Modeling	Minimaal twee geschikte voorspellende modellen correct getraind.	8

Fase	Criterium	Punten
Modeling	Cross-validatie, beperkte tuning en onderbouwde selectie van eindmodel.	8
Evaluation	Confusion matrix en vereiste testmetriecken correct berekend en uitgelegd.	8
Evaluation	Eerlijke vergelijking met baseline en validatieresultaten.	5
Evaluation	Foutanalyse en passende modelinterpretatie.	7
Evaluation	Direct antwoord op businessvraag, beperkingen en passend advies.	5

Totaal: 100 punten. Een technisch werkend model zonder aantoonbare data-analyse en datavoorbereiding kan niet de maximale score behalen.

6. Controlelijst voor inlevering

47. De businessvraag staat letterlijk in mijn werk.
48. Mijn notebook volgt de vijf gebruikte CRISP-DM-fasen.
49. Ik heb alle 14 kolommen getypeerd en inhoudelijk beschreven.
50. Ik heb datakwaliteit met code, aantallen en percentages onderzocht.
51. Ik heb mijn opschoningskeuzes zichtbaar en beargumenteerd uitgevoerd.
52. Ik heb minimaal vijf nieuwe kenmerken gemaakt.
53. Mijn model gebruikt geen `end_time`, `duration_minutes`, `long_disruption` of `rdt_id` als invoerkenmerk.
54. Mijn preprocessing is alleen op trainingsdata gefit.
55. Ik heb een baseline en minimaal twee voorspellende modellen vergeleken.
56. Ik heb het eindmodel eenmaal op de testset getest en fouten geanalyseerd.
57. Ik heb de businessvraag beantwoord en minimaal drie beperkingen besproken.
58. Alle bestanden openen en het notebook draait zonder lokale absolute paden.

Bijlage A. Beknopt kolommenoverzicht

Gebruik de meegeleverde databeschrijving voor de volledige definities. Dit overzicht helpt bij het indelen van de variabelen. Bepaal zelf de uiteindelijke technische datatypes en modelrollen.

Kolom	Betekenis	Voorlopige inhoudelijke vorm
rdt_id	Uniek verstorings-ID	Identifier
ns_lines	Getroffen trajecten uit het NS-storingsbericht	Niet-gestandaardiseerde tekst
rdt_lines	Door Rijden de Treinen gekoppelde trajecten	Multi-value categorische tekst
rdt_lines_id	ID's van gekoppelde trajecten	Multi-value identifiertekst
rdt_station_names	Namen van getroffen stations	Multi-value categorische tekst
rdt_station_codes	Codes van getroffen stations	Multi-value identifiertekst
cause_nl	Laatst getoonde storingsoorzaak in het Nederlands	Categorisch
cause_en	Vertaling van cause_nl	Categorisch
statistical_cause_nl	Statistische storingsoorzaak in het Nederlands	Categorisch
statistical_cause_en	Vertaling van statistical_cause_nl	Categorisch
cause_group	Engelstalige storinggroep	Categorisch
start_time	Starttijd van de verstoring	Datum/tijd
end_time	Eindtijd van de verstoring	Datum/tijd
duration_minutes	Geregistreerde duur in minuten	Numeriek